

水面垃圾清理船

垃圾识别算法技术报告

—— 2022 年竞赛项目算法部分复盘整理 ——

项目：第十五届国际先进机器人及仿真技术大赛·创新设计赛·一等奖

载体：无人水面垃圾清理船（海丝一队·实物组）

整理人：张启元（船组组长，负责整体技术统筹与识别算法推进）

工作时间口径：2022 年 3 月 — 2022 年 11 月

整理时间：2026 年 9 月

本文档为赛后整理的算法层面技术复盘，内容以 2022 年项目执行期的
实际做法、实测数据与当时的技术认知为准。

一、任务定义与约束条件

项目载体为一艘遥控双体垃圾清理船：双体结构 + 吃入式收集 + 侧推进器零半径转向，由岸边操作手遥控作业。算法部分的任务是给这条船装上“眼睛”——通过船载摄像头对水面漂浮垃圾进行**实时的类别识别与定位**，为操作手提供目标指引（垃圾在哪、是什么），提升遥控清理的效率；同时岸端同步观察水面画面与识别结果。

任务成立时即明确了四条硬约束，它们贯穿了后续所有技术决策：

约束	具体内容	对算法的含义
算力	机载算力预算只能支撑嵌入式平台（选定 NVIDIA Jetson Nano，128 核 Maxwell GPU + 4 核 A57 CPU，4GB 共享内存）	模型规模与输入分辨率受严格限制
功耗	船体电池需同时供推进器、舵机与计算板，功耗模式限 5W / 10W 两档	不能靠堆功耗换帧率
实时性	识别结果要能跟上船的行进节奏，否则对遥控作业无意义	实际目标定为 ≥ 15 FPS
周期	2022 年 3 月立项、11 月参赛，期间与船体、电控并行推进	优先采用成熟组件，不押注不稳定的新方法

二、总体技术路线

当时的总体路线是一条“**算力预算先行**”的链路：先部署平台，再反推模型规模，最后围绕模型需要的数据缺口做数据集建设——而不是先训大模型再考虑怎么塞进板子。



这一顺序的关键考虑：嵌入式平台的算力上限在选型阶段就已锁定，若最后才发现模型跑不动，返工成本极高；而数据集建设是整条链路里周期最长、最不可压缩的环节，必须最早启动。

三、数据集构建（本项目最核心的工作）

3.1 为什么必须自建

2022 年检索可用的垃圾检测公开数据集后发现两个问题：

- **水下数据为主、水面数据稀缺**：主流数据集（如基于 J-EDI 深海视频的 Trash-ICRA19）由 AUV 在深海拍摄，普遍存在色偏、雾化、对比度低等失真，与船载摄像头在 daylight 水面视角下的成像差异显著，直接迁移效果存疑；
- **细分类别样本稀缺**：当时唯一面向水面漂浮垃圾的公开集 FloW 仅 2000 张图像、以瓶罐类为主，难以支撑塑料袋、泡沫、纸板等细分类别的训练。

结论：**水面子集必须自己采集扩充**，水下部分则可以基于公开集标注改造，验证"水面为主、兼顾水下"的识别能力。

3.2 数据构成与采集方式

子集	来源	采集/获取方式	标注类别
水面垃圾子集	FloW 公开集（约 2000 张）+ 校区水域自采	在校区水域布放塑料袋、塑料瓶等典型垃圾，以无人船搭载摄像头按作业视角拍摄；与 FloW 混合后整理筛选	塑料瓶、塑料袋、塑料泡沫、纸板
水下垃圾子集	Trash-ICRA19（J-EDI 深海影像库）	AUV 深海视频分帧筛选，重新按本任务目标标注	塑料瓶、塑料袋、海洋生物

自采数据刻意保持了**视角一致性**——相机高度、俯角、距离均模拟清理船实际作业状态，而不是随手在岸边拍摄。事后看这是自建集对模型实船效果贡献最大的一点：训练分布与部署分布基本对齐，岸上测试通过后上船几乎不需要重新调参。

3.3 规模、增广与划分

- 两个子集整理筛选后合并约 **14,487 张**（提交口径），按 **8 : 1 : 1** 划分训练 / 验证 / 测试集（11,587 / 1,450 / 1,450）；
- 对样本量不足的类别使用几何增广（旋转、翻转）扩充，未使用色调 / 光照类增广（当时对水面反光、眩光问题的预估不足，这一点在局限性分析中展开）；
- 标注后做交叉抽查质检，重点核查漏标（水面背景杂物易被忽略）与框贴合度。

四、模型选型

4.1 检测范式：单阶段 vs 两阶段

2022 年的目标检测主流分两派：以 Faster R-CNN 为代表的两阶段方法精度高但计算量大、推理慢；以 YOLO / SSD 为代表的单阶段方法牺牲部分精度换取速度与模型轻量。本任务是"嵌入式 + 实时 + 低功耗"，精度需求是"人眼可信、位置够指引遥控"而非自动驾驶级，**单阶段是明确更契合的范式**。

4.2 具体模型：YOLOv5

选定 YOLOv5 的理由按当时权重排序：

- 1. **工程成熟度**：训练、导出、部署链路完备，社区文档完善——对八个月竞赛周期，链路可跑通比论文指标更重要；
- 2. **规模可选**：n / s / m / l / x 五档网络规模，同一套训练代码即可在"精度—速度"间换挡，便于适配部署平台；
- 3. **小目标友好**：水面漂浮垃圾在画面中普遍偏小（FloW 中占比最大的目标小于 32×32 像素），YOLOv5 输入端的 mosaic 拼接与多尺度训练对此有帮助。

4.3 规模档位：n 级

在 3050 级消费卡上的预实验给出选型依据：**n 级模型在该数据上的精度损失相对 s 级很小，推理速度优势却直接决定能否在 Nano 上达到实时**。对"识别结果指引遥控"的任务定位，n 级精度足够——把速度预算留在量化之后仍能站上 15 FPS 的安全线上，这是最终拍板 n 级的原因。（该判断后经 2026 年的复现实验支持：同源数据上 n 级模型的精度与更新的 n 级版本持平，见附录 C。）

选型小结：范式（单阶段）→ 模型（YOLOv5）→ 档位（n 级）三层决策全部由部署约束反推，而不是从精度排行榜正向选择。嵌入式项目里"能部署的模型"优先于"最好的模型"。

五、训练与评估

5.1 训练环境与超参

环境		训练超参	
GPU	NVIDIA RTX 3090 24GB	训练轮次	300（约 200 轮后收敛）
框架	PyTorch 1.12 / CUDA 11.3 / Ubuntu 18.04	输入尺寸	640 × 640
初始化	COCO 预训练权重（迁移学习）	优化器 / 学习率	SGD / 0.01
早停	100 轮无提升即停	batch size / 权值衰减	32 / 0.0005

采用 COCO 预训练迁移学习的原因：自建集规模有限（万级），从头训练易过拟合且收敛慢；COCO 预训练权重提供了通用目标特征，实测明显加快收敛。水面与水下两个子集使用相同平台、相同参数分别训练。

5.2 评估结果（水面漂浮垃圾模型）

指标	类别				总体
	塑料瓶	塑料袋	泡沫	纸板	
精确率 P	0.96	0.91	0.93	0.94	0.909
召回率 R	0.90	0.89	0.93	0.96	0.893
F1	0.93	0.90	0.93	0.95	0.897
mAP@0.5	0.95	0.90	0.94	0.95	0.94
mAP@0.5:0.95（估算*）	0.60	0.54	0.59	0.60	≈ 0.58

* mAP@0.5 与 P / R / F1 为当时训练评估记录的整理值（其中 F1 由 P、R 推得）；mAP@0.5:0.95 当时未记录，为复盘整理时按同源数据复现实验中 mAP50-95 与 mAP50 的典型比值（0.60–0.65）推算的**估算值**，仅供量级参考，非实测记录。

水下子集模型同流程训练，三类目标（塑料瓶 / 塑料袋 / 海洋生物）精确率与召回率保持在 0.90 上下，mAP@0.5 约 0.94（mAP@0.5:0.95 估算约 0.62）。

5.3 错误模式分析（混淆矩阵观察）

- **类别间混淆极少**：四类目标互相认错的比例很小，说明类别特征区分度高；
- **主要错误是背景误检（FP）**：波光、岸边倒影等背景被误判为目标次数多于类间混淆，是后续现场调阈值的主要对象；
- **塑料袋召回略低**：塑料袋形变大、常半浸没、受风浪遮挡，是四类中最难的目标；
- **塑料瓶最稳定**——刚性目标、形态收敛，与预期一致。

六、量化压缩与边缘部署

6.1 为什么必须量化

海洋 / 湖泊作业无法依赖云端算力，识别必须完全在机载设备完成；而 Nano 无独立大显存、模型默认 FP32 计算量大，直接部署帧率不达标。因此对训练好的 YOLOv5 做**压缩量化：合并部分网络层（卷积 + BN 融合）、压缩模型数值精度**，在精度损失可接受的范围内显著降低计算量。

6.2 实测帧率 (Jetson Nano, 最终部署形态)

模型形态	功耗模式	FPS	结论
YOLOv5 (FP32)	5W	6	不可用
	10W	11	勉强可用, 无余量
量化后 YOLOv5	5W	10	续航优先的备用档
	10W	18	实船采用: 满足 ≥15 FPS 实时目标

量化使 10W 模式帧率从 11 FPS 提升至 **18 FPS (约 +64%)** , 5W 模式从 6 提升至 10。最终实船采用 10W 模式运行量化模型; 5W 模式作为高续航需求时的降级档位。

6.3 机载识别系统组成

USB 摄像头 (船首安装, 模拟作业俯角) → Jetson Nano (量化模型推理, 画面取帧检测, 目标以矩形框 + 类别 + 置信度标注) → 岸端屏显 (图传同步观察水面画面与识别结果, 辅助遥控决策)。供电独立于动力电池, 避免推进器负载波动影响计算板。

七、船载联调与比赛实测

识别系统完成部署后装配上船, 在校区水域进行实地测试: 清理船作业的同时对水面垃圾实时识别, 识别框稳定叠加在回传画面上, 操作手依据标注引导船体靠近并收集。实测中系统表现出足够的实时性与较高的识别精度, 达到了"给遥控清理提供目标指引"的设计目标。

时间线说明 (对应参赛设计报告的表述差异): 参赛设计报告在**比赛前**提交, 当时识别系统仍处联调收尾阶段, 报告因此写明"识别系统还未完善、无法在比赛过程中使用"; 提交之后到比赛之前, 量化部署与船载联调完成, **比赛时识别系统已实船运行**。两份材料的时间差属于"先交报告、后比赛"的流程时序, 并非工作未完成。

八、局限性分析 (以 2022 年当时的认知复盘)

8.1 数据层面

- **规模与覆盖有限:** 总量万级、类别四类 (水面) , 对真实水域的垃圾形态多样性覆盖不足;
- **自采场景单一:** 单一校区水域、固定季节与光照区间, 跨水域 / 跨季节泛化未验证 (该局限判断后经 2026 年跨域复现评测印证: 模型在异构公开水下数据集上 mAP@0.5 明显下降, 见附录 C) ;
- **增广策略偏保守:** 仅用旋转、翻折等几何增广, 未做光照、色调、水面反光模拟——而背景误检 (波光、倒影) 恰是实测中的主要错误来源, 两者错配是当时明显的考虑不周;
- **类别不均衡:** 泡沫、纸板样本量显著少于塑料瓶 / 塑料袋, 长尾类别指标波动大;
- **水下失真未处理:** 水下手集的色偏、雾化没有做针对性图像增强, 水下指标受此拖累 (该问题在项目后续阶段才被系统研究) 。

8.2 模型层面

- **小目标风险**：远距离小目标（ $<32 \times 32$ 像素）漏检概率高，实际靠操作手控制船靠近来弥补；
- **背景误检未根治**：波光、倒影类 FP 靠整体置信度阈值压制，未做类别自适应阈值；
- **形变目标召回偏低**：塑料袋半浸没、褶皱形态下召回约 0.89，是四类最低。

8.3 部署层面

- **量化精度损失未系统评估**：当时只对比了量化前后的帧率，**没有做量化前后 mAP 的对照实验**，精度损失靠肉眼验收——这是当时实验设计上最应该补的一环；
- **分辨率—帧率权衡刚性**：Nano 算力下 640 输入已接近上限，无法通过提分辨率换小目标精度；
- **功耗两难**：10W 换实时性，但压缩了续航；5W 档帧率不足以支撑连续作业。

8.4 系统层面

- **识别与航行未闭环**：识别结果只做“指引”，船由人遥控——识别→航向的自主闭环（含避障、返航）未实现，是当时明确的边界而非遗漏；
- **夜间与恶劣天气未验证**：所有实测均在日间良好光照下进行；
- **无现场数据回流机制**：实地测试中发现的误检样本没有形成“回流—再训练”的闭环，错过的样本价值很大。

九、路线复盘：当时的决策逻辑与如果重来

9.1 当时做对了什么

1. **部署约束前置**：先锁平台与功耗档，再反推模型规模，避免了“训完才发现跑不动”的返工；
2. **视角一致的自采数据**：自采集按作业视角拍摄，训练分布与部署分布对齐，是实船效果好的最大功臣——比多塞几千张异构公开图更有价值；
3. **n 级 + 量化的组合拳**：两层“降算力”手段叠加，才把帧率从 6（FP32/5W）做到 18（量化/10W），任何单层手段都到不了实时线；
4. **COCO 迁移学习**：小数据集上收敛快、稳，为并行推进的船体联调省出了时间。

9.2 如果重来（以当时可及的手段）

1. **补量化感知训练 / 量化前后精度对照**：量化只验了速度没验精度；应做 PT 前后 mAP 对照，必要时候选感知量化训练；
2. **光照与反光增广**：针对波光、倒影 FP 主错误源，在增广管线中加亮度扰动、镜面高光模拟、局部过曝，比换更大模型收益更确定；
3. **现场误检样本回流**：联调阶段把误检帧攒下来做定向补充标注与再训练，形成小闭环；
4. **类别自适应阈值**：按类别设定置信度阈值（塑料袋放低、塑料瓶持平），平衡长尾召回与背景误检。

9.3 一句话总结

这是一条“约束驱动的极简路线”：任务上把自主导航明确划出边界、只做识别指引；工程上用数据分布对齐 + 小模型 + 量化三层手段，在 10W 功耗预算内把实时识别做实。它的价值在于可复现、可解释——每个决策都能回答“为什么这么做”。

附录 A：关键指标汇总

项目	数值	口径来源
数据集总量（水面 + 水下，筛选后）	14,487 张（8:1:1 划分）	参赛设计报告
水面模型总体 P / R / F1	0.909 / 0.893 / 0.897	参赛设计报告
水面模型 mAP@0.5	0.94（分类别 0.90–0.95）	训练评估记录整理
水面模型 mAP@0.5:0.95	≈ 0.58	复盘估算（非实测）
水下模型 P / R（三类均值）	约 0.90 / 0.90	训练评估记录整理
水下模型 mAP@0.5 / mAP@0.5:0.95	0.94 / ≈ 0.62（后者为估算）	记录 + 复盘估算
Jetson Nano 帧率（FP32 → 量化）	5W：6 → 10；10W：11 → 18 FPS	实测测试
训练收敛轮次	约 200 / 300 轮	训练曲线

附录 B：训练环境配置

项	配置
操作系统	Ubuntu 18.04
CPU / GPU	14 核 Intel Xeon Gold 6330 / NVIDIA RTX 3090 24GB
加速库 / 框架	CUDA 11.3.1 / PyTorch 1.12.0（Python 3.10）
部署平台	NVIDIA Jetson Nano（128 核 Maxwell GPU + 四核 A57，4GB，5W/10W 两档）

附录 C：复现验证（2026 年，独立于 2022 年原始口径）

为验证当时技术判断的稳健性，2026 年将项目数据重组后进行了独立的复现训练与跨域评测。复现实验与 2022 年原始实验并非同一数据划分与训练代码版本，结果仅作量级与相对比较参考，不与正文 2022 年口径混用。

C.1 n 级模型选型的复现支持

模型 (n 级规模)	P	R	mAP@0.5	mAP@0.5:0.95
YOLOv5n (复现训练)	0.952	0.948	0.982	0.792
更新版本的 n 级模型 A	0.948	0.961	0.985	0.801
更新版本的 n 级模型 B	0.950	0.961	0.984	0.805

同源数据上，YOLOv5n 与后续年份发布的更新的 n 级模型精度基本持平（差异在测量噪声内）。**结论：当时"选成熟版本 + n 级规模"的决策在精度上没有付出可见代价**——嵌入式场景下没有必要为不可见的精度差异放弃已验证的部署链路。

C.2 跨域泛化评测（印证 8.1 节局限判断）

评测集	P	R	mAP@0.5	mAP@0.5:0.95
TrashCAN（水下垃圾，风格较接近）	0.851	0.717	0.783	0.559
ICRA19（深海 AUV 视角，域差异大）	0.378	0.438	0.322	0.178

模型在训练分布内指标很高，但换到异构域（尤其深海 AUV 视角）后 mAP@0.5 由 0.9 量级跌至 0.32。这定量印证了 8.1 节"自采场景单一、跨域泛化未验证"的局限判断：**当时模型的优异指标高度依赖"采集视角与部署视角一致"这一前提**，跨域部署需要目标域数据补充或域自适应——这也是该局限在后续工作中的改进方向。

说明：本文档为赛后整理稿，用于完整呈现 2022 年项目执行期算法部分的技术路线、实测数据与局限。正文指标以当时实验与测试记录为准，其中明确标注"估算"者（mAP@0.5:0.95）为复盘时推算、非实测；附录 C 为 2026 年独立复现验证，与 2022 年原始口径分离呈现。因参赛设计报告提交于联调完成前，其"识别系统未完善"的表述与本文档的差异见第七节时间线说明。